

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN TỐT NGHIỆP

NGHIÊN CỨU CÁC THUẬT TOÁN HỌC MÁY VÀ ỨNG DỤNG DỰ ĐOÁN BỆNH TIM MẠCH

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: LƯƠNG TRUNG ĐỨC
MÃ SINH VIÊN: 10122125
MÃ LỚP: 124221
GIẢNG VIÊN HƯỚNG DẪN: TS. PHẠM MINH CHUẨN

NHẬN XÉT

Nhận xét của giáo viên hướng dẫn

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIẢNG VIÊN HƯỚNG DẪN

Phạm Minh Chuẩn

LỜI CAM ĐOAN

Tôi xin cam đoan đề án tốt nghiệp “Nghiên cứu các thuật toán học máy và ứng dụng dự đoán bệnh tim mạch” là sản phẩm của bản thân tôi, được thực hiện dựa trên quá trình nghiên cứu, lập trình và thực nghiệm độc lập.

Những phần sử dụng tài liệu tham khảo trong đề án đã được trích dẫn rõ ràng trong phần tài liệu tham khảo. Các kết quả trình bày trong báo cáo được tổng hợp từ mã nguồn thực nghiệm và dữ liệu do tác giả xử lý.

Nếu vi phạm lời cam đoan này, tôi xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày ... tháng 06 năm 2026

Sinh viên

Đức

Lương Trung Đức

LỜI CẢM ƠN

Để có thể hoàn thành đồ án tốt nghiệp này, lời đầu tiên em xin trân trọng gửi lời cảm ơn tới bộ môn Khoa học máy tính, Khoa Công nghệ thông tin, Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo điều kiện thuận lợi cho em trong quá trình học tập và thực hiện đề tài.

Đặc biệt em xin chân thành cảm ơn thầy Phạm Minh Chuẩn đã tận tình hướng dẫn, định hướng và góp ý cho em trong suốt quá trình nghiên cứu đề tài dự đoán bệnh tim mạch bằng các thuật toán học máy.

Em cũng xin chân thành cảm ơn tất cả các Thầy, các Cô trong Khoa Công nghệ thông tin đã tận tình giảng dạy, trang bị cho em những kiến thức nền tảng về lập trình, cơ sở dữ liệu, trí tuệ nhân tạo và khoa học dữ liệu.

Mặc dù tôi đã có cố gắng, nhưng với trình độ còn hạn chế, trong quá trình thực hiện đề tài không tránh khỏi những thiếu sót. Tôi hy vọng sẽ nhận được những ý kiến nhận xét, góp ý của các Thầy cô về những kết quả triển khai trong đồ án.

Tôi xin trân trọng cảm ơn!

MỤC LỤC

DANH SÁCH HÌNH ẢNH	5
DANH SÁCH BẢNG	7
CHƯƠNG 1. TỔNG QUAN	8
1.1. Lý do chọn đề tài	8
1.2. Mục tiêu đề tài	9
1.3. Giới hạn và phạm vi của đề tài	10
1.4. Phương pháp tiếp cận	10
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	13
2.1. Tổng quan về học máy trong dự đoán y tế	13
2.2. Bài toán phân loại nhị phân	13
2.3. Dummy Classifier	14
2.4. Logistic Regression	15
2.5. Gaussian Naive Bayes	17
2.6. K-Nearest Neighbors (KNN)	19
2.7. Support Vector Machine (SVM)	21
2.8. Decision Tree	23
2.9. Random Forest	25
2.10. Extra Trees	27
2.11. XGBoost	28
2.12. LightGBM	30
2.13. CatBoost	32
2.14. Các thước đo đánh giá mô hình	33
2.15. Tối ưu ngưỡng và giải thích mô hình	35

2.16. Kết chương	36
CHƯƠNG 3. NỘI DUNG THỰC HIỆN	37
3.1. Khảo sát dữ liệu và kiểm tra đầu vào	37
3.2. Thiết kế chia tập dữ liệu chống rò rỉ	42
3.3. Thiết kế pipeline tiền xử lý và feature engineering	42
3.4. So sánh 11 mô hình baseline	43
3.5. Tinh chỉnh siêu tham số, lựa chọn mô hình và kiểm định chéo lồng	44
3.6. Hiệu chuẩn xác suất và khóa ngưỡng quyết định	46
3.7. Đánh giá cuối cùng trên hold-out test	48
3.8. Kiểm tra độ ổn định và độ tin cậy	50
3.9. Giải thích mô hình và tầm quan trọng đặc trưng	53
3.10. Kiểm tra công bằng, drift và khả năng tổng quát hóa	55
3.11. Thực nghiệm đối chiếu trên các dataset phụ	56
3.12. Đóng gói mô hình và ứng dụng minh họa	57
3.13. Kết chương	59
KẾT LUẬN	60
TÀI LIỆU THAM KHẢO	63

DANH SÁCH HÌNH ẢNH

Hình 2.1 : Hàm sigmoid trong Logistic Regression.	15
Hình 2.2 : giả định Gaussian trong Gaussian Naive Bayes.	17
Hình 2.3 : Nguyên lý láng giềng gần nhất của KNN.	19
Hình 2.4 : Siêu phẳng tối ưu và margin của SVM.	21
Hình 2.5 : Cấu trúc phân nhánh của Decision Tree.	23
Hình 2.6 : Random Forest với nhiều cây bỏ phiếu đa số.	25
Hình 2.7 : Extra Trees với các ngưỡng chia ngẫu nhiên.	27
Hình 2.8 : Cơ chế boosting tuần tự của XGBoost.	28
Hình 2.9 : Cơ chế leaf-wise growth của LightGBM.	30
Hình 2.10 : Ordered encoding và ordered boosting của CatBoost.	32
Hình 3.1 : Bộ dữ liệu trên kaggle	37
Hình 3.2 : Diễn giải mức cholesterol và glucose trong dataset	40
Hình 3.3 : Phân bố nhãn mục tiêu cardio	40
Hình 3.4 : Phân bố các biến phân loại và nhị phân theo nhãn	41
Hình 3.5 : KDE của một số biến lâm sàng quan trọng theo nhãn	41
Hình 3.6 : Ma trận tương quan của các biến số lâm sàng	41
Hình 3.7 : So sánh 11 mô hình baseline trên các chỉ số chính	44
Hình 3.8 : Calibration curve trước và sau hiệu chuẩn sigmoid	47
Hình 3.9 : Đồ thị các chỉ số theo ngưỡng quyết định	48
Hình 3.10 : Đường ROC và Precision-Recall trên hold-out test	50
Hình 3.11 : Decision curve analysis trên hold-out test	50
Hình 3.12 : Learning curve của mô hình theo kích thước tập huấn luyện	52
Hình 3.13 : SHAP summary plot cho các đặc trưng quan trọng nhất	54

Hình 3.14 : SHAP dependence plot cho đặc trưng ap_hi_clean	54
Hình 3.15 : SHAP dependence plot cho đặc trưng age_years	55
Hình 3.16 : Calibration theo từng nhóm con (subgroup)	56
Hình 3.17 : Giao diện ứng dụng dự đoán bệnh tim mạch	58

DANH SÁCH BẢNG

Bảng 3.1 : Mô tả các đặc trưng ban đầu của bộ dữ liệu	38
Bảng 3.2 : Thống kê tổng quan bộ dữ liệu và cấu hình thực nghiệm	39
Bảng 3.3 : Diễn giải mức cholesterol và glucose trong dataset	39
Bảng 3.4 : Diễn giải mức cholesterol và glucose trong dataset	42
Bảng 3.5 : Các nhóm đặc trưng sau khi biến đổi lâm sàng	43
Bảng 3.6 : So sánh 11 mô hình baseline bằng cross-validation	44
Bảng 3.7 : Kết quả RandomizedSearchCV của top candidates	45
Bảng 3.8 : Kết quả chọn mô hình/calibrator trên val_select	45
Bảng 3.9 : Kết quả nested/outer CV của các mô hình top	46
Bảng 3.10 : So sánh CatBoost trước/sau sigmoid calibration	46
Bảng 3.11 : Khóa ngưỡng quyết định trên tập val_threshold	47
Bảng 3.12 : Kết quả đánh giá mô hình trên hold-out test	49
Bảng 3.13 : Ma trận nhầm lẫn trên hold-out test	49
Bảng 3.14 : Khoảng tin cậy 95% bằng bootstrap trên hold-out test	51
Bảng 3.15 : So sánh mô hình cuối với Logistic Regression trên test	51
Bảng 3.16 : Robustness studies chính	52
Bảng 3.17 : Tầm quan trọng đặc trưng top 10	53
Bảng 3.18 : Tổng hợp kiểm tra fairness theo nhóm	56

CHƯƠNG 1. TỔNG QUAN

Chương 1 trình bày bối cảnh lựa chọn đề tài, mục tiêu nghiên cứu, phạm vi thực hiện và phương pháp tiếp cận tổng quát. Nội dung chương này được xây dựng dựa trên quy trình thực nghiệm, trong đó phân tích dữ liệu khám phá được tách biệt với phần huấn luyện và đánh giá mô hình nhằm làm rõ từng giai đoạn nghiên cứu. Quy trình vẫn đảm bảo các yêu cầu quan trọng như chia dữ liệu chống rò rỉ, hiệu chuẩn xác suất, lựa chọn mô hình, khóa ngưỡng quyết định và đánh giá cuối cùng trên tập hold-out test.

1.1. Lý do chọn đề tài

Bệnh tim mạch là nhóm bệnh nguy hiểm, có ảnh hưởng lớn tới sức khỏe cộng đồng và chi phí điều trị. Trong thực tế khám sàng lọc, các thông tin cơ bản như tuổi, giới tính, chiều cao, cân nặng, huyết áp, mức cholesterol, mức glucose và thói quen sinh hoạt thường được ghi nhận sớm. Đây là dạng dữ liệu bảng phù hợp để ứng dụng các thuật toán học máy nhằm ước lượng nguy cơ ban đầu.

Đề tài “Nghiên cứu các thuật toán học máy và ứng dụng dự đoán bệnh tim mạch” được thực hiện trên bộ Cardiovascular Disease Dataset của Sulianova trên Kaggle, gồm 70.000 bản ghi và 13 cột ban đầu. Biến mục tiêu là cardio, trong đó cardio = 0 biểu thị không ghi nhận bệnh tim mạch và cardio = 1 biểu thị có ghi nhận bệnh tim mạch theo nhãn dữ liệu.

Điểm quan trọng của đề tài không chỉ là đạt chỉ số đánh giá cao, mà là xây dựng một quy trình thực nghiệm chặt chẽ, có khả năng giải thích và bảo vệ trước hội đồng. Quy trình bao gồm kiểm tra cấu trúc dữ liệu và miền giá trị, phát hiện trùng đặc trưng và xung đột nhãn, chia dữ liệu theo nhóm đặc trưng để tránh trùng lặp giữa các tập, đóng gói tiền xử lý trong Pipeline, tinh chỉnh mô hình bằng cross-validation và chỉ đánh giá trên tập test sau khi mô hình, phương pháp hiệu chuẩn và ngưỡng quyết định đã được khóa.

Trong kết quả thực nghiệm, mô hình cuối được chọn là CatBoost kết hợp hiệu chuẩn xác suất sigmoid và ngưỡng quyết định 0,3650. Trên tập hold-out test gồm 10.000 mẫu, mô hình đạt ROC-AUC = 0,8083, PR-AUC = 0,7995, Brier score = 0,1774, Accuracy = 0,7161, Precision = 0,6792, Recall = 0,8185, Specificity = 0,6138 và F2-score = 0,7862.

Các kết quả này cho thấy mô hình có giá trị như một minh chứng học thuật cho bài toán sàng lọc sơ bộ, nhưng không được diễn giải như một hệ thống chẩn đoán y tế.

1.2. Mục tiêu đề tài

Mục tiêu tổng quát của đề tài là nghiên cứu, triển khai và so sánh các thuật toán học máy cho bài toán phân loại nhị phân nguy cơ bệnh tim mạch, từ đó xây dựng một pipeline dự đoán có thể tái lập, có hiệu chuẩn xác suất, có giải thích mô hình và có thể đóng gói để phục vụ ứng dụng minh họa.

- Khảo sát bộ dữ liệu `cardio_train.csv` gồm 70.000 bản ghi, 13 cột ban đầu và tỷ lệ lớp dương `cardio = 1` xấp xỉ 0,4997.
- Kiểm tra schema, dtype, missing value và miền giá trị của các biến `gender`, `cholesterol`, `gluc`, `smoke`, `alco`, `active` và `cardio`; xác nhận dữ liệu đầu vào gốc không có giá trị thiếu.
- Làm rõ ý nghĩa của `cholesterol` và `gluc`: đây là mã ordinal 1/2/3 trong dataset, được gán nhãn tham chiếu bình thường, cao hơn bình thường và rất cao; không phải giá trị xét nghiệm mg/dL trực tiếp của từng bệnh nhân.
- Thiết kế `CardioFeatureEngineer` trong Pipeline để tạo `age_years`, `height_clean`, `weight_clean`, `bmi`, `ap_hi_clean`, `ap_lo_clean`, `pulse_pressure`, `map_proxy`, `age_group`, `bmi_group`, `bp_stage` và các `invalid_flag`.
- So sánh 11 mô hình: `DummyClassifier`, `LogisticRegression`, `GaussianNB`, `KNN`, `SVM`, `DecisionTree`, `RandomForest`, `ExtraTrees`, `XGBoost`, `LightGBM` và `CatBoost` bằng 5-fold `StratifiedGroupKFold`.
- Tinh chỉnh các mô hình ứng viên bằng `RandomizedSearchCV` với `n_iter = 25`, lựa chọn mô hình/calibrator trên `val_select` bằng selection score, kiểm tra thêm các ensemble soft-voting top models, hiệu chuẩn xác suất bằng sigmoid trên `val_cal` và khóa threshold trên `val_threshold`.
- Đánh giá cuối cùng trên hold-out test 10.000 mẫu bằng ROC-AUC, PR-AUC, Brier score, log loss, Accuracy, Precision, Recall, Specificity, F1, F2 và ma trận nhầm lẫn.

- Kiểm tra độ tin cậy bằng bootstrap 600 lần, bootstrap độ ổn định threshold, learning curve, kiểm định thống kê với Logistic Regression, SHAP, permutation importance, subgroup/fairness, drift monitoring, OOD sanity check và robustness studies.
- Lưu model package final_model.joblib cùng model_card.json/model_card.md và các artifact báo cáo để phục vụ tái lập, thuyết trình và triển khai minh họa.

1.3. Giới hạn và phạm vi của đề tài

Đề tài được giới hạn trong phạm vi nghiên cứu học thuật và thực nghiệm trên dữ liệu công khai. Các giới hạn chính gồm:

- Dữ liệu sử dụng là Cardiovascular Disease Dataset của Sulianova trên Kaggle, không phải dữ liệu bệnh viện Việt Nam và không có đầy đủ metadata về quy trình thu thập.
- Hai biến cholesterol và gluc chỉ là mã ordinal 1/2/3. Các mức mg/dL được dùng như ngưỡng tham chiếu để diễn giải, không được coi là giá trị xét nghiệm thật trong từng dòng dữ liệu.
- Dataset chỉ có các biến lâm sàng cơ bản; chưa có LDL/HDL, triglyceride, HbA1c, ECG, troponin, tiền sử gia đình, thuốc đang sử dụng, bệnh nền hoặc yếu tố xã hội.
- Bài toán được thiết lập là phân loại nhị phân theo nhãn cardio của dataset; không dự đoán thời gian mắc bệnh, mức độ bệnh hoặc nguy cơ biến cố tim mạch trong tương lai.
- Mô hình cuối là proof-of-concept phục vụ sàng lọc sơ bộ và học thuật; không thay thế chẩn đoán của bác sĩ, chưa có external validation đúng schema, chưa có prospective validation và chưa được kiểm định lâm sàng.

1.4. Phương pháp tiếp cận

Quy trình thực nghiệm được tổ chức thành hai nhóm công việc chính. Nhóm thứ nhất tập trung vào đọc dữ liệu, kiểm tra cấu trúc, kiểm toán dữ liệu, chia tập, xây dựng đặc trưng và phân tích dữ liệu khám phá trên tập huấn luyện. Nhóm thứ hai tập trung vào so sánh

mô hình, tinh chỉnh siêu tham số, hiệu chuẩn xác suất, lựa chọn mô hình, tối ưu ngưỡng quyết định, đánh giá trên tập test, giải thích mô hình và xuất các artifact phục vụ báo cáo.

Các giai đoạn chính gồm:

- Đọc dữ liệu bằng dấu phân tách ;, kiểm tra đủ 13 cột, kiểm tra kiểu dữ liệu dạng số và miền giá trị hợp lệ cho các biến nhị phân, biến thứ bậc và biến mục tiêu.
- Tạo chữ ký đặc trưng từ toàn bộ biến đầu vào, không bao gồm id và cardio; kiểm tra bản ghi trùng, dòng trùng hoàn toàn và xung đột nhãn nhưng không xóa dòng theo biến mục tiêu trước khi chia dữ liệu.
- Chia dữ liệu theo chiến lược group-aware thành 5 tập: train, val_cal, val_select, val_threshold và test; xác nhận không có trùng nhóm đặc trưng giữa các tập.
- Thực hiện phân tích dữ liệu khám phá chỉ trên tập train nhằm tránh data snooping, bao gồm phân bố nhãn, kiểm tra giá trị y khoa bất thường, tương quan, VIF, tỷ lệ nguy cơ theo nhóm và univariate ROC-AUC.
- Đóng gói feature engineering, imputation, scaling, one-hot encoding và mô hình trong sklearn Pipeline/ColumnTransformer để bảo đảm mỗi fold cross-validation được fit độc lập.
- So sánh 11 mô hình baseline bằng StratifiedGroupKFold 5-fold, sau đó tinh chỉnh các mô hình ứng viên tốt nhất bằng RandomizedSearchCV trên tập train thông qua cross-validation.
- Fit calibrator trên tập hiệu chuẩn, chọn mô hình và phương pháp hiệu chuẩn trên tập xác thực lựa chọn, kiểm tra thêm ensemble từ các mô hình tốt nhất nhưng vẫn khóa lựa chọn theo tiêu chí đã đăng ký trước.
- Khóa ngưỡng quyết định trên tập xác thực ngưỡng và chỉ sử dụng tập test cho báo cáo kết quả cuối cùng.
- Giải thích và kiểm tra mô hình bằng SHAP, permutation importance, bootstrap confidence interval, bootstrap độ ổn định ngưỡng, learning curve, kiểm định

DeLong/McNemar/paired bootstrap, phân tích subgroup/fairness, drift monitoring và robustness studies.

- Thực nghiệm đối chiếu ba notebook phụ theo cùng xương sống pipeline: kiểm tra dữ liệu, split trước preprocessing, xử lý missing/imbalance trong Pipeline, tối ưu threshold trên validation và báo cáo test độc lập.

Với cách tiếp cận này, báo cáo ưu tiên tính đúng phương pháp, khả năng tái lập và khả năng giải thích hơn là chỉ tối đa hóa một chỉ số đơn lẻ trên tập test.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

Chương 2 trình bày cơ sở lý thuyết phục vụ cho việc xây dựng và đánh giá các mô hình học máy trong bài toán dự đoán bệnh tim mạch. Nội dung chương tập trung vào 11 thuật toán phân loại đã được sử dụng trong mã nguồn thực nghiệm: từ baseline đơn giản (Dummy Classifier), các mô hình tuyến tính và xác suất (Logistic Regression, Naive Bayes), các mô hình hình học (KNN, SVM), các mô hình dựa trên cây quyết định (Decision Tree, Random Forest, Extra Trees) cho đến các mô hình gradient boosting hiện đại (XGBoost, LightGBM, CatBoost). Cuối chương trình bày các thước đo đánh giá mô hình và các kỹ thuật tối ưu ngưỡng, giải thích mô hình.

2.1. Tổng quan về học máy trong dự đoán y tế

Học máy (Machine Learning) là một nhánh của trí tuệ nhân tạo, tập trung vào việc xây dựng các thuật toán có khả năng học từ dữ liệu để đưa ra dự đoán hoặc quyết định mà không cần được lập trình tường minh cho từng tình huống cụ thể. Trong y tế, học máy đặc biệt hữu ích cho bài toán sàng lọc nguy cơ vì có thể tận dụng đồng thời nhiều biến số lâm sàng, học các mối quan hệ phi tuyến phức tạp giữa chúng và đưa ra ước lượng xác suất rủi ro cho từng cá nhân.

Mặt khác, các mô hình học máy y tế đặt ra những yêu cầu đặc thù: xác suất dự đoán phải có ý nghĩa lâm sàng (cần được hiệu chuẩn), mô hình phải có khả năng giải thích được (cho cả bác sĩ và bệnh nhân), kết quả phải ổn định trên các quần thể khác nhau, và đặc biệt phải ưu tiên giảm tỉ lệ bỏ sót bệnh (false negative) hơn là giảm tỉ lệ cảnh báo nhầm (false positive). Đề tài này được thiết kế bám theo các yêu cầu trên.

2.2. Bài toán phân loại nhị phân

Phân loại nhị phân là bài toán dự đoán nhãn đầu ra thuộc một trong hai lớp, ký hiệu $y \in \{0, 1\}$. Trong đề tài này, $y = 1$ nghĩa là người bệnh có nguy cơ mắc bệnh tim mạch, $y = 0$ nghĩa là không có nguy cơ. Mô hình học máy nhận đầu vào là vector đặc trưng x và sinh ra một giá trị xác suất $p(x) \in [0, 1]$ đại diện cho khả năng $y = 1$. Quyết định cuối cùng được đưa ra bằng cách so sánh $p(x)$ với một ngưỡng τ :

$$\hat{y} = 1 \text{ nếu } p(x) \geq \tau; \hat{y} = 0 \text{ nếu } p(x) < \tau \quad (2.1)$$

Trong các bài toán y tế, ngưỡng τ thường được chọn nhỏ hơn 0,5 nhằm ưu tiên giảm bỏ sót, nghĩa là chấp nhận tăng false positive để giảm false negative. Phần 3.5 sẽ trình bày chi tiết quá trình khóa ngưỡng theo F2-score.

2.3. Dummy Classifier

a. Khái niệm

Dummy Classifier là một mô hình phân loại đơn giản nhất, được sử dụng làm baseline tham chiếu để đánh giá liệu các mô hình phức tạp hơn có thực sự học được gì có ý nghĩa hay không.

b. Nguyên lý hoạt động

Dummy Classifier không sử dụng đặc trưng đầu vào để học bất kỳ mối quan hệ nào với nhãn. Trong mã nguồn thực nghiệm, mô hình được cấu hình với `strategy="stratified"`, nghĩa là dự đoán nhãn theo phân bố tần suất các lớp trong tập huấn luyện một cách ngẫu nhiên có trọng số.

c. Công thức

$$\hat{y} \sim \text{Categorical}(\pi_0, \pi_1), \pi_c = n_c / n \quad (2.2)$$

d. Tham số quan trọng

Tham số chính là `strategy`. Với `strategy="stratified"`, mô hình ngẫu nhiên hóa các dự đoán theo phân bố tần suất lớp. Các giá trị khác gồm `"most_frequent"` (luôn dự đoán lớp đa số), `"prior"` (dùng xác suất tiên nghiệm), `"uniform"` (ngẫu nhiên đều).

e. Ưu điểm

Đơn giản, không cần huấn luyện, đóng vai trò baseline khách quan để so sánh với các mô hình phức tạp.


f. Nhược điểm

Không có khả năng học từ đặc trưng đầu vào, nên không thể đưa ra dự đoán có ý nghĩa cho từng cá nhân. ROC-AUC luôn xấp xỉ 0,5.

g. Khả năng áp dụng cho bài toán tim mạch

Dummy Classifier không phải là mô hình triển khai mà chỉ đóng vai trò mức sàn. Mọi mô hình thực sự được sử dụng đều phải vượt rõ rệt Dummy Classifier về tất cả các chỉ số (ROC-AUC, F2-score, recall) thì mới có giá trị.

2.4. Logistic Regression



Hình 2.1: Hàm sigmoid trong Logistic Regression.

a. Khái niệm

Logistic Regression (Hồi quy logistic) là mô hình phân loại tuyến tính dựa trên phép biến đổi sigmoid của một tổ hợp tuyến tính các đặc trưng. Đây là một trong những mô hình học máy được sử dụng phổ biến nhất trong y tế vì có nền tảng thống kê chặt chẽ và dễ giải thích.

b. Nguyên lý hoạt động

Mô hình tính một điểm số tuyến tính $z = w^T x + b$ từ vector đặc trưng đầu vào x , sau đó đưa qua hàm sigmoid để chuyển thành xác suất $p(y = 1 | x)$. Các trọng số w và bias b được học bằng cách cực đại hoá hàm log-likelihood (hoặc tương đương: cực tiểu hoá Binary Cross-Entropy).

c. Công thức

$$p(y = 1 | x) = \sigma(w^T x + b) \quad (2.3)$$

$$\sigma(z) = 1 / (1 + e^{(-z)}) \quad (2.4)$$

$$L(w, b) = - (1/n) \sum [y_i \log(\pi_i) + (1 - y_i) \log(1 - \pi_i)] \quad (2.5)$$

d. Tham số quan trọng

Trong mã nguồn thực nghiệm, Logistic Regression được cấu hình với `max_iter=4000`, `solver="lbfgs"` và `class_weight="balanced"`. Tham số `class_weight="balanced"` tự động điều chỉnh trọng số nghịch đảo theo tần suất lớp, giúp xử lý mất cân bằng nhẹ. Solver `lbfgs` là phương pháp quasi-Newton hiệu quả cho bài toán có nhiều mẫu.

e. Ưu điểm

Dễ giải thích (các hệ số w trực tiếp cho biết mức ảnh hưởng của từng biến), có nền tảng thống kê chặt chẽ, huấn luyện nhanh, ít rủi ro overfitting trên dữ liệu lớn, xác suất đầu ra tự nhiên có thể hiệu chuẩn tốt.


f. Nhược điểm

Chỉ học được mối quan hệ tuyến tính giữa đặc trưng và log-odds nên không thể nắm bắt các tương tác phi tuyến phức tạp giữa các biến nếu không feature engineering thủ công.

g. Khả năng áp dụng cho bài toán tim mạch

Logistic Regression là baseline có ý nghĩa cho bài toán tim mạch. Nhiều thang điểm rủi ro tim mạch trong y văn (ví dụ Framingham Risk Score, ASCVD Risk Estimator) đều dựa trên hồi quy logistic. Trong đề tài này, Logistic Regression vừa là baseline tham chiếu vừa là mô hình giải thích cơ sở.

2.5. Gaussian Naive Bayes



Hình 2.2: giả định Gaussian trong Gaussian Naive Bayes.

a. Khái niệm

Gaussian Naive Bayes là mô hình phân loại xác suất dựa trên định lý Bayes với giả định mạnh rằng các đặc trưng là độc lập có điều kiện với nhau khi biết lớp, và mỗi đặc trưng tuân theo phân phối Gauss.

b. Nguyên lý hoạt động

Mô hình tính xác suất hậu nghiệm $P(Y = c | x)$ bằng định lý Bayes, kết hợp xác suất tiên nghiệm $P(Y = c)$ và xác suất khả năng (likelihood) của từng đặc trưng $P(x_j | Y = c)$. Với Gaussian NB, likelihood được mô hình hóa bằng phân phối chuẩn.

c. Công thức

$$P(Y = c | x) = P(Y = c) \prod_j P(x_j | Y = c) / P(x) \quad (2.6)$$

$$P(x_j | Y = c) = 1 / \sqrt{(2\pi\sigma^2)_{jc}} \cdot \exp(- (x_j - \mu_{jc})^2 / (2\sigma^2)_{jc}) \quad (2.7)$$

d. Tham số quan trọng

Mã nguồn thực nghiệm sử dụng GaussianNB với cấu hình mặc định. Tham số quan trọng nhất là `var_smoothing` (mặc định $1e-9$) — một hệ số làm trơn được cộng vào phương sai để tránh lỗi chia cho 0 khi phương sai gần 0.

e. Ưu điểm

Huấn luyện cực nhanh, ít tham số cần điều chỉnh, hiệu năng tốt khi dữ liệu thực sự gần phân phối Gauss và các đặc trưng tương đối độc lập.


f. Nhược điểm

Giả định độc lập có điều kiện thường không đúng trong dữ liệu y tế thực tế (ví dụ: huyết áp tâm thu và tâm trương rõ ràng tương quan với nhau). Mô hình cũng nhạy cảm khi đặc trưng không tuân theo phân phối Gauss.

g. Khả năng áp dụng cho bài toán tim mạch

Naive Bayes thường có hiệu năng thấp hơn các mô hình phức tạp trên dữ liệu tim mạch do giả định độc lập bị vi phạm. Tuy nhiên, đây vẫn là baseline xác suất có ý nghĩa, đặc biệt khi cần đánh giá tốc độ huấn luyện hoặc khi dữ liệu rất nhỏ.

2.6. K-Nearest Neighbors (KNN)



Hình 2.3: Nguyên lý láng giềng gần nhất của KNN.

a. Khái niệm

K-Nearest Neighbors (K láng giềng gần nhất) là mô hình phân loại phi tham số dựa trên nguyên tắc: nhãn của một điểm được dự đoán dựa trên nhãn của K điểm dữ liệu gần nhất với nó trong không gian đặc trưng.

b. Nguyên lý hoạt động

Khi nhận một mẫu mới x , mô hình tính khoảng cách từ x đến tất cả các điểm trong tập huấn luyện, chọn ra K điểm gần nhất, sau đó lấy nhãn theo biểu quyết đa số. KNN không thực sự “huấn luyện” — nó chỉ ghi nhớ toàn bộ dữ liệu huấn luyện và thực hiện toàn bộ tính toán tại thời điểm dự đoán (lazy learner).

c. Công thức

$$d(x, x_i) = \sqrt{(\sum_j (x_j - x_{ij})^2)} \quad (2.8)$$

$$\hat{y} = \text{mode}\{y_i : x_i \in N_k(x)\} \quad (2.9)$$

d. Tham số quan trọng

Trong mã nguồn thực nghiệm, KNN được cấu hình với `n_neighbors=51`, `weights="distance"`, `metric="minkowski"`, `p=2` và `n_jobs=-1`. Lựa chọn `K=51` (số lẻ lớn) phù hợp với dữ liệu lớn 70.000 mẫu, giúp giảm nhiễu cục bộ. `weights="distance"` cho phép các láng giềng gần đóng góp nhiều hơn vào quyết định, theo nghịch đảo khoảng cách. `metric="minkowski"` với `p=2` chính là khoảng cách Euclidean.

e. Ưu điểm

Đơn giản, dễ hiểu về mặt trực giác, không cần giả định về phân phối dữ liệu, có thể nắm bắt các ranh giới phân loại phức tạp (phi tuyến).


f. Nhược điểm

Tốc độ dự đoán chậm trên dữ liệu lớn do phải tính khoảng cách đến mọi điểm. Nhạy cảm với scale của các biến (cần chuẩn hóa). Hiệu năng giảm trong không gian nhiều chiều (curse of dimensionality).

g. Khả năng áp dụng cho bài toán tim mạch

KNN có thể đạt hiệu năng tương đối tốt trên bài toán tim mạch khi các biến số đã được chuẩn hóa cẩn thận. Tuy nhiên, do tốc độ inference chậm trên 70.000 mẫu, KNN không phù hợp để triển khai trong ứng dụng web thực tế.

2.7. Support Vector Machine (SVM)



Hình 2.4: Siêu phẳng tối ưu và margin của SVM.

a. Khái niệm

Support Vector Machine (Máy hỗ trợ vector) là mô hình phân loại tìm siêu phẳng tách biệt hai lớp với biên (margin) lớn nhất giữa các điểm gần ranh giới nhất (support vectors). Phiên bản tuyến tính (LinearSVC) đặc biệt phù hợp với dữ liệu nhiều mẫu vì có thể huấn luyện hiệu quả mà không cần kernel trick.

b. Nguyên lý hoạt động

Mô hình LinearSVC tìm siêu phẳng $w^T x + b = 0$ sao cho cực tiểu hoá tổng của hai thành phần: thành phần regularization $\frac{1}{2}\|w\|^2$ (giúp biên lớn) và thành phần phạt sai số (hinge loss) cho các điểm bị phân loại sai hoặc nằm trong vùng biên. Trong mã nguồn thực nghiệm, một lớp tùy chỉnh LinearSVCSigmoid được tạo ra: nó kế thừa LinearSVC và bổ sung phương thức `predict_proba` bằng cách áp dụng sigmoid lên `decision_function`. Điều này cho phép cross-validation với scoring cần xác suất (như Average Precision) hoạt động được.

c. Công thức

$$\min(w, b, \xi) \quad 1/2 ||w||^2 + C \sum \xi_i \quad (2.10)$$

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (2.11)$$

d. Tham số quan trọng

Mã nguồn cấu hình LinearSVCSigmoid với $C=1.0$, `class_weight="balanced"`, `max_iter=10000` và `dual=False`. Tham số C kiểm soát mức độ phạt sai số: C nhỏ $\rightarrow$ biên rộng, C lớn $\rightarrow$ biên hẹp, dễ overfit. `dual=False` thích hợp khi số mẫu lớn hơn số đặc trưng (đúng với tập 70.000 mẫu $\times$ ~20 đặc trưng).

e. Ưu điểm

Cơ sở lý thuyết chặt chẽ về biên lớn, hiệu quả với dữ liệu nhiều chiều, ít overfit hơn các mô hình tham số khác khi dữ liệu nhỏ.

f. Nhược điểm


LinearSVC chỉ học được ranh giới tuyến tính. Không có `predict_proba` mặc định, phải tự áp dụng sigmoid hoặc Platt scaling. Nhạy cảm với scale của đặc trưng.

g. Khả năng áp dụng cho bài toán tim mạch

SVM tuyến tính là mô hình tham chiếu tốt cho bài toán tim mạch khi đã có pipeline tiền xử lý chuẩn hóa cẩn thận. Tuy nhiên, do giả thiết tuyến tính, hiệu năng thường thấp hơn các mô hình ensemble như Random Forest hoặc Gradient Boosting.

2.8. Decision Tree

Decision Tree: chuỗi quyết định dạng cây



Hình 2.5: Cấu trúc phân nhánh của Decision Tree.

a. Khái niệm

Decision Tree (Cây quyết định) là mô hình phân loại có cấu trúc dạng cây, trong đó mỗi nút trong là một quy tắc phân nhánh dựa trên một đặc trưng và một ngưỡng, các nhánh con đại diện cho các kết quả có thể, và mỗi lá là một dự đoán nhãn lớp.

b. Nguyên lý hoạt động

Mô hình được xây dựng đệ quy bằng cách chọn cặp (đặc trưng, ngưỡng) tối ưu hóa một tiêu chí thuần khiết tại mỗi nút. Hai tiêu chí phổ biến nhất là Gini impurity và Entropy. Quá trình tiếp tục cho đến khi đạt một điều kiện dừng: độ sâu tối đa, số mẫu tối thiểu trong nút, hoặc khi nút đã thuần khiết hoàn toàn.

c. Công thức

$$\text{Gini}(S) = 1 - \sum_k p_k^2 \quad (2.12)$$

$$H(S) = - \sum_k p_k \log_2(p_k) \quad (2.13)$$

d. Tham số quan trọng

Mã nguồn cấu hình DecisionTreeClassifier với max_depth=6, min_samples_leaf=80 và class_weight="balanced". Tham số max_depth=6 giới hạn độ sâu của cây để tránh overfitting nghiêm trọng, min_samples_leaf=80 yêu cầu mỗi lá phải có ít nhất 80 mẫu, đảm bảo các quy tắc đủ tin cậy thống kê.

e. Ưu điểm

Dễ hiểu và trực quan hóa được, không yêu cầu chuẩn hóa đặc trưng, có thể nắm bắt mối quan hệ phi tuyến và tương tác giữa các biến.


f. Nhược điểm

Một cây đơn lẻ thường có phương sai cao và overfit nếu không được điều chỉnh cẩn thận. Hiệu năng kém hơn các phương pháp ensemble.

g. Khả năng áp dụng cho bài toán tim mạch

Decision Tree đơn lẻ ít khi được dùng làm mô hình triển khai cuối, nhưng rất có giá trị như một công cụ giải thích: bác sĩ có thể đọc các quy tắc phân nhánh để hiểu mô hình đang phân loại bệnh nhân theo logic nào.

2.9. Random Forest



Hình 2.6: Random Forest với nhiều cây bỏ phiếu đa số.

a. Khái niệm

Random Forest là mô hình ensemble kết hợp nhiều cây quyết định độc lập, mỗi cây được huấn luyện trên một mẫu bootstrap của dữ liệu và chỉ xét một tập con ngẫu nhiên các đặc trưng tại mỗi điểm chia nhánh. Dự đoán cuối cùng được lấy bằng biểu quyết đa số (cho phân loại) hoặc trung bình (cho hồi quy).

b. Nguyên lý hoạt động

Phương pháp Bagging (Bootstrap Aggregating) tạo ra nhiều cây độc lập bằng cách lấy mẫu có hoàn lại (bootstrap) từ tập huấn luyện. Tại mỗi nút, thay vì xét toàn bộ đặc trưng, chỉ một tập con ngẫu nhiên được xét, làm tăng tính đa dạng giữa các cây. Việc kết hợp nhiều cây giúp giảm phương sai mà không làm tăng độ chệch.

c. Công thức

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_B(x)\} \quad (2.14)$$

d. Tham số quan trọng

Mã nguồn cấu hình RandomForestClassifier với `n_estimators=350`, `min_samples_leaf=25` và `class_weight="balanced_subsample"`. Số cây 350 là sự cân bằng giữa hiệu năng và thời gian huấn luyện. `min_samples_leaf=25` đảm bảo các lá đủ tin cậy. `class_weight="balanced_subsample"` tính lại trọng số lớp trên mỗi mẫu bootstrap.

e. Ưu điểm

Hiệu năng tốt trên đa số bài toán dạng bảng, ít cần điều chỉnh siêu tham số, ít overfit hơn cây đơn lẻ, cung cấp ước lượng tầm quan trọng đặc trưng hữu ích.


f. Nhược điểm

Mô hình lớn (kích thước file lớn), thời gian huấn luyện và inference chậm hơn các mô hình tuyến tính, khả năng giải thích kém hơn cây đơn lẻ.

g. Khả năng áp dụng cho bài toán tim mạch

Random Forest là một trong những mô hình mạnh và ổn định cho bài toán tim mạch, đặc biệt với dữ liệu có nhiều biến số có ngưỡng phi tuyến (huyết áp, BMI, cholesterol). Trong đề tài này, Random Forest cũng là một trong các mô hình ứng viên được tinh chỉnh.

2.10. Extra Trees



Hình 2.7: Extra Trees với các ngưỡng chia ngẫu nhiên.

a. Khái niệm

Extra Trees (Extremely Randomized Trees) là biến thể của Random Forest, khác ở chỗ ngưỡng chia nhánh được chọn ngẫu nhiên thay vì tìm kiếm tối ưu trên đặc trưng được chọn.

b. Nguyên lý hoạt động

Tại mỗi nút, Extra Trees chọn ngẫu nhiên một tập con đặc trưng (giống Random Forest), nhưng với mỗi đặc trưng, ngưỡng chia được lấy ngẫu nhiên trong khoảng $[\min, \max]$ của đặc trưng đó, thay vì tìm ngưỡng tối ưu. Điều này tăng tính ngẫu nhiên và giảm thêm phương sai.

c. Công thức

$$\theta_j \sim U(\min(x_j), \max(x_j)) \quad (2.15)$$

d. Tham số quan trọng

Mã nguồn cấu hình ExtraTreesClassifier với `n_estimators=350`, `min_samples_leaf=25` và `class_weight="balanced"` — gần như giống Random Forest, chỉ khác phương thức chọn ngưỡng.

e. Ưu điểm

Huấn luyện nhanh hơn Random Forest do không phải tìm ngưỡng tối ưu, đôi khi ổn định hơn trên dữ liệu nhiễu.


f. Nhược điểm

Có thể có độ chệch cao hơn Random Forest do ngưỡng được chọn ngẫu nhiên, không tối ưu thực sự cho từng nút.

g. Khả năng áp dụng cho bài toán tim mạch

Extra Trees là một ứng viên hợp lý cho bài toán tim mạch, đặc biệt khi cần huấn luyện nhanh trên dữ liệu lớn. Hiệu năng thường tương đương Random Forest và đôi khi tốt hơn nhờ tính ngẫu nhiên cao hơn.

2.11. XGBoost



Hình 2.8: Cơ chế boosting tuần tự của XGBoost.

a. Khái niệm

XGBoost (eXtreme Gradient Boosting) là một thư viện gradient boosting tối ưu hóa cao, được thiết kế để có hiệu năng và tốc độ vượt trội. Nó kế thừa ý tưởng gradient boosting

truyền thống nhưng bổ sung nhiều cải tiến về toán học (regularization L1, L2 trong hàm mục tiêu) và kỹ thuật (parallel processing, sparsity-aware split, weighted quantile sketch).

b. Nguyên lý hoạt động

XGBoost xây dựng mô hình theo từng giai đoạn (boosting). Tại mỗi giai đoạn, một cây mới được thêm vào để bổ khuyết phần dự đoán còn sai (residual) của mô hình tích lũy. Điểm mới của XGBoost là sử dụng khai triển Taylor bậc hai của hàm mất mát để có công thức cập nhật chính xác hơn, kèm regularization để kiểm soát độ phức tạp của cây.

c. Công thức

$$\text{Obj} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (2.16)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_j w_j^2 + \alpha \sum_j |w_j| \quad (2.17)$$

d. Tham số quan trọng

Mã nguồn cấu hình XGBClassifier với `n_estimators=450`, `max_depth=3`, `learning_rate=0.035`, `subsample=0.85`, `colsample_bytree=0.85`, `min_child_weight=3`, `reg_alpha=0.05`, `reg_lambda=1.5`, `objective="binary:logistic"`, `eval_metric="logloss"`, `tree_method="hist"`. Cấu hình này nhằm cân bằng giữa độ chính xác và khả năng tổng quát hóa: cây nông (`depth=3`) kết hợp với `learning rate` thấp và nhiều cây (450), regularization L1+L2 đầy đủ.

e. Ưu điểm

Hiệu năng cực cao trên dữ liệu dạng bảng, được nhiều cuộc thi Kaggle chứng minh là một trong những mô hình mạnh nhất. Hỗ trợ regularization tốt, xử lý missing values tự nhiên, có thể huấn luyện song song.


f. Nhược điểm

Nhiều siêu tham số cần điều chỉnh (cần các kỹ thuật tự động như RandomizedSearchCV). Có thể overfit nếu không cẩn thận với `learning rate` và regularization. Khả năng giải thích kém hơn các mô hình tuyến tính.

g. Khả năng áp dụng cho bài toán tim mạch

XGBoost là một trong các mô hình hàng đầu cho bài toán tim mạch trên bộ dữ liệu này. Trong đề tài, XGBoost là ứng viên top-3 và được tinh chỉnh siêu tham số bằng RandomizedSearchCV.

2.12. LightGBM



Hình 2.9: Cơ chế leaf-wise growth của LightGBM.

a. Khái niệm

LightGBM là thư viện gradient boosting do Microsoft phát triển, được thiết kế cho tốc độ và hiệu năng trên dữ liệu lớn. Khác với XGBoost xây cây theo level-wise (mỗi level có chiều sâu tương đương), LightGBM dùng leaf-wise growth: chọn lá có gain lớn nhất để mở rộng, giúp giảm loss nhanh hơn nhưng dễ overfit hơn nếu dữ liệu nhỏ.

b. Nguyên lý hoạt động

LightGBM sử dụng hai kỹ thuật chính: Gradient-based One-Side Sampling (GOSS) — giữ lại các mẫu có gradient lớn (khó học) và lấy mẫu ngẫu nhiên các mẫu gradient nhỏ (dễ học) — và Exclusive Feature Bundling (EFB) — gom nhiều đặc trưng thừa thành

một bó, giảm số lần quét. Hai kỹ thuật này giúp LightGBM nhanh hơn XGBoost đáng kể trên dữ liệu lớn.

c. Công thức

$$\text{Gain} = 1/2 [GL^2/(HL + \lambda) + GR^2/(HR + \lambda) - G^2/(H + \lambda)] - \gamma \quad (2.18)$$

d. Tham số quan trọng

Mã nguồn cấu hình LGBMClassifier với `n_estimators=450`, `learning_rate=0.035`, `num_leaves=31`, `min_child_samples=60`, `subsample=0.85`, `colsample_bytree=0.85`, `reg_alpha=0.05`, `reg_lambda=1.5`. Tham số `num_leaves=31` (tương đương $2^5 - 1$) là cấu hình mặc định cân bằng giữa tốc độ và độ chính xác. `min_child_samples=60` tránh overfit ở các lá nhỏ.

e. Ưu điểm

Tốc độ huấn luyện nhanh hơn XGBoost, đặc biệt trên dữ liệu lớn. Sử dụng bộ nhớ ít hơn nhờ EFB. Hỗ trợ huấn luyện trên GPU.


f. Nhược điểm

Leaf-wise growth có thể overfit trên dữ liệu nhỏ nếu `num_leaves` quá lớn. Nhạy cảm hơn XGBoost với cấu hình siêu tham số.

g. Khả năng áp dụng cho bài toán tim mạch

LightGBM cùng nhóm hiệu năng cao với XGBoost và CatBoost trên bài toán này. Đặc biệt với 70.000 mẫu, LightGBM có lợi thế về tốc độ huấn luyện/inference và vẫn là một ứng viên mạnh. Tuy nhiên, theo quy tắc selection đã khóa trong kết quả mới, mô hình cuối cùng của đề tài là CatBoost + sigmoid calibration chứ không phải LightGBM.

2.13. CatBoost



Hình 2.10: Ordered encoding và ordered boosting của CatBoost.

a. Khái niệm

CatBoost (Categorical Boosting) là thư viện gradient boosting do Yandex phát triển, đặc biệt mạnh trong xử lý đặc trưng phân loại (categorical features) một cách tự động và hiệu quả thông qua kỹ thuật ordered boosting.

b. Nguyên lý hoạt động

CatBoost giải quyết hai vấn đề chính của gradient boosting truyền thống: (1) prediction shift do dữ liệu huấn luyện cùng được dùng để fit model và để tính residual, dẫn đến overfit có hệ thống; và (2) target leakage khi mã hoá biến categorical bằng target encoding. CatBoost dùng ordered boosting (chia ngẫu nhiên dữ liệu thành các giai đoạn và mỗi cây chỉ thấy phần trước đó) và ordered target statistics (tính CTR theo thứ tự ngẫu nhiên).

c. Công thức

$$CTR_i = (\sum_{j < i} [x_j = x_i] y_j + aP) / (\sum_{j < i} [x_j = x_i] + a) \quad (2.19)$$

Trong đó: x_j duyệt qua các mẫu trước mẫu hiện tại theo permutation ngẫu nhiên, a là hệ số làm trơn (smoothing), P là xác suất tiên nghiệm.

d. Tham số quan trọng

Mã nguồn cấu hình CatBoostClassifier với `iterations=450`, `depth=5`, `learning_rate=0.035`, `l2_leaf_reg=6.0`, `loss_function="Logloss"`, `eval_metric="AUC"`. CatBoost dùng symmetric trees (cây cân bằng), khác với XGBoost/LightGBM. `depth=5` là cấu hình thường dùng cho CatBoost (tương đương về khả năng biểu diễn so với cây không cân bằng sâu hơn).

e. Ưu điểm

Xử lý categorical features tự động và hiệu quả, ít cần feature engineering, ít overfit nhờ ordered boosting, hiệu năng cao mà không cần tinh chỉnh nhiều siêu tham số.

f. Nhược điểm

Tốc độ huấn luyện chậm hơn LightGBM trên dữ liệu lớn. File mô hình lớn hơn. Cộng đồng và tài liệu nhỏ hơn so với XGBoost.

g. Khả năng áp dụng cho bài toán tim mạch

CatBoost là một trong các mô hình ứng viên top-3 cho bài toán tim mạch. Trong đề tài, CatBoost cho hiệu năng tương đương với XGBoost/LightGBM theo các chỉ số ROC-AUC và Average Precision.

2.14. Các thước đo đánh giá mô hình

Việc đánh giá mô hình phân loại y tế đòi hỏi sử dụng nhiều thước đo khác nhau để có cái nhìn toàn diện. Mỗi thước đo phản ánh một khía cạnh khác nhau của hiệu năng, và việc chỉ dựa vào một chỉ số đơn lẻ (như Accuracy) có thể dẫn đến kết luận sai lầm.

a. Accuracy

Accuracy là tỉ lệ dự đoán đúng trên tổng số mẫu. Đây là chỉ số đơn giản nhất nhưng không phản ánh tốt khi dữ liệu mất cân bằng.

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN}) \quad (2.20)$$

b. Precision và Recall

Precision (độ chính xác) là tỉ lệ dự đoán dương tính đúng trong tổng số dự đoán dương tính. Recall (độ nhạy, sensitivity) là tỉ lệ phát hiện được trong tổng số ca dương tính thực sự.

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}) \quad (2.21)$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN}) \quad (2.22)$$

Trong y tế, Recall thường quan trọng hơn Precision vì bỏ sót một ca bệnh có hậu quả nghiêm trọng hơn so với cảnh báo nhầm.

c. Specificity

Specificity là tỉ lệ phát hiện đúng các ca âm tính, giúp đánh giá khả năng phân loại đúng người không bệnh.

$$\text{Specificity} = \text{TN} / (\text{TN} + \text{FP}) \quad (2.23)$$

d. F1 và F-beta

F1-score là trung bình điều hòa của Precision và Recall, cân bằng cả hai chỉ số. F-beta là tổng quát hóa, với $\beta > 1$ ưu tiên Recall hơn Precision ($\beta = 2$ cho F2-score).

$$\text{F1} = 2 \cdot \text{Precision} \cdot \text{Recall} / (\text{Precision} + \text{Recall}) \quad (2.24)$$

$$\text{F}\beta = (1 + \beta^2) \cdot \text{Precision} \cdot \text{Recall} / (\beta^2 \cdot \text{Precision} + \text{Recall}) \quad (2.25)$$

Trong đề tài này, F2-score được sử dụng làm tiêu chí khóa ngưỡng vì ưu tiên Recall trong bài toán sàng lọc.

e. Brier score và Calibration

Brier score đo độ chính xác của xác suất dự đoán: càng nhỏ càng tốt (0 là hoàn hảo). Một mô hình có ROC-AUC cao nhưng Brier score lớn nghĩa là xếp hạng đúng nhưng xác suất bị lệch — cần hiệu chuẩn lại.

$$\text{Brier} = (1/N) \sum_{i=1}^N (p_i - y_i)^2 \quad (2.26)$$

f. ROC-AUC và Average Precision

ROC-AUC là diện tích dưới đường ROC, đo khả năng xếp hạng các mẫu dương tính cao hơn các mẫu âm tính. $AUC = 0,5$ là ngẫu nhiên, $AUC = 1,0$ là hoàn hảo. Average Precision (AP) là diện tích dưới đường Precision–Recall, đặc biệt hữu ích khi dữ liệu mất cân bằng.

$$ROC - AUC = P(\text{score}(x+) > \text{score}(x-)) \quad (2.27)$$

2.15. Tối ưu ngưỡng và giải thích mô hình

a. Khóa ngưỡng quyết định

Ngưỡng mặc định 0,5 không phải lúc nào cũng phù hợp với bài toán y tế. Khóa ngưỡng là quá trình quét các giá trị ngưỡng từ 0 đến 1 trên một tập validation và chọn ngưỡng tối ưu hóa một tiêu chí cụ thể (F2-score, recall với ràng buộc specificity, v.v.). Trong đề tài, ngưỡng được khóa theo F2-score để ưu tiên giảm bỏ sót.

b. Hiệu chuẩn xác suất (Calibration)

Hiệu chuẩn xác suất là quá trình điều chỉnh xác suất dự đoán để chúng phản ánh đúng tần suất thực tế. Hai phương pháp phổ biến: sigmoid (Platt scaling) — fit một logistic regression đơn giản trên xác suất; và isotonic regression — phương pháp phi tham số. Đề tài sử dụng sigmoid vì dữ liệu lớn và sigmoid ít overfit hơn isotonic.

c. SHAP và Permutation Importance

SHAP (SHapley Additive exPlanations) là phương pháp giải thích mô hình dựa trên giá trị Shapley từ lý thuyết trò chơi hợp tác. SHAP value cho mỗi đặc trưng đại diện cho mức đóng góp của đặc trưng đó vào dự đoán cụ thể, với tính chất cộng tính: tổng SHAP của tất cả đặc trưng + baseline = dự đoán cuối cùng. Permutation Importance đo mức suy giảm hiệu năng khi giá trị một đặc trưng bị xáo trộn ngẫu nhiên.

d. Bootstrap và Learning Curve

Bootstrap là kỹ thuật ước lượng khoảng tin cậy bằng cách lấy mẫu lại có hoàn lại (600 lần trong thực nghiệm) từ tập test và tính lại các chỉ số. Learning curve cho thấy hiệu

năng thay đổi như thế nào khi tăng kích thước tập huấn luyện, giúp phát hiện underfitting/overfitting.

2.16. Kết chương

Chương 2 đã trình bày cơ sở lý thuyết của 11 thuật toán phân loại được sử dụng trong đề tài, được sắp xếp từ baseline đơn giản (Dummy Classifier) đến các mô hình hiện đại (XGBoost, LightGBM, CatBoost). Mỗi mô hình được mô tả qua khái niệm, nguyên lý hoạt động, công thức toán học cơ bản, các tham số quan trọng được sử dụng trong mã nguồn thực nghiệm, ưu nhược điểm và khả năng áp dụng cho bài toán tim mạch.

Chương cũng trình bày các thước đo đánh giá mô hình quan trọng (Accuracy, Precision, Recall, Specificity, F1, F-beta, Brier score, ROC-AUC, Average Precision) và các kỹ thuật tối ưu ngưỡng, hiệu chuẩn xác suất, giải thích mô hình bằng SHAP và Permutation Importance. Đây là cơ sở lý thuyết để Chương 3 trình bày quá trình thực nghiệm cụ thể trên bộ dữ liệu Cardiovascular Disease Dataset.

CHƯƠNG 3. NỘI DUNG THỰC HIỆN

Chương 3 trình bày toàn bộ nội dung thực nghiệm của đề tài, bao gồm các bước đọc và kiểm tra dữ liệu, kiểm toán dữ liệu nhằm hạn chế rò rỉ thông tin, chia tập theo chiến lược group-aware, phân tích dữ liệu khám phá chỉ trên tập huấn luyện, xây dựng pipeline tiền xử lý, so sánh 11 mô hình học máy, tinh chỉnh các mô hình ứng viên tốt nhất, kiểm tra ensemble, lựa chọn mô hình cuối là CatBoost kết hợp hiệu chuẩn xác suất sigmoid, khóa ngưỡng quyết định 0,3650 và đánh giá độc lập trên tập hold-out test. Ngoài thực nghiệm chính trên Sulianova, chương này bổ sung bảng đối chiếu với Heart Failure Prediction và Framingham Heart Study để làm rõ khả năng áp dụng quy trình trên các dataset tim mạch khác schema.

3.1. Khảo sát dữ liệu và kiểm tra đầu vào

Bộ dữ liệu đầu vào là cardio_train.csv, gồm 70.000 bản ghi và 13 cột ban đầu. Cột id chỉ là mã dòng và không được dùng làm đặc trưng huấn luyện. Cột age được lưu theo đơn vị ngày và được chuyển thành age_years trong CardioFeatureEngineer. Các biến cholesterol và gluc là mã ordinal 1/2/3 theo data dictionary của dataset.

id	age	gender	height	weight	ap_hi
ID number	in days	1 - women, 2 - men	cm	kg	Systolic b
0	18393	2	168	62.0	110
1	20228	1	156	85.0	140
2	18857	1	165	64.0	130
3	17623	2	169	82.0	150
4	17474	1	156	56.0	100
8	21914	1	151	67.0	120
9	22113	1	157	93.0	130
12	22584	2	178	95.0	130

Hình 3.1: Bộ dữ liệu trên kaggle

Bảng 3.1: Mô tả các đặc trưng ban đầu của bộ dữ liệu

Cột	Ý nghĩa	Vai trò trong mô hình
id	Mã dòng dữ liệu	Loại khỏi feature để tránh nhiễu
age	Tuổi tính theo ngày	Chuyển thành age_years
gender	Giới tính mã hóa 1/2	Biến nhị phân/ordinal passthrough
height	Chiều cao (cm)	Làm sạch và dùng tính BMI
weight	Cân nặng (kg)	Làm sạch và dùng tính BMI
ap_hi	Huyết áp tâm thu	Làm sạch, tạo bp_stage, pulse_pressure, map_proxy
ap_lo	Huyết áp tâm trương	Làm sạch, tạo bp_stage, pulse_pressure, map_proxy
cholesterol	Mức cholesterol 1/2/3	Giữ ordinal và diễn giải theo mức tham chiếu
gluc	Mức glucose 1/2/3	Giữ ordinal và diễn giải theo mức tham chiếu
smoke	Có hút thuốc không	Biến nhị phân
alco	Có uống rượu không	Biến nhị phân
active	Có vận động không	Biến nhị phân
cardio	Nhãn bệnh tim mạch 0/1	Biến mục tiêu


Bảng 3.2: Thống kê tổng quan bộ dữ liệu và cấu hình thực nghiệm

Hạng mục	Giá trị
Số bản ghi ban đầu	70.000
Số cột ban đầu	13
Biến mục tiêu	cardio
Tỷ lệ lớp dương toàn bộ dữ liệu	0,4997
Số missing đầu vào gốc	0
Số nhóm feature_signature duy nhất	69.959
Số mô hình baseline so sánh	11
CV chính	5-fold StratifiedGroupKFold
Tuning budget	RandomizedSearchCV, n_iter = 25, max_tuned = 5
Bootstrap CI	600 lần
Mô hình cuối	CatBoost + sigmoid calibration, threshold = 0,3650


Bảng 3.3: Diễn giải mức cholesterol và glucose trong dataset

Biến	Mức	Nhãn trong dataset	Ngưỡng tham chiếu diễn giải	Số mẫu	Tỷ lệ
cholesterol	1	Bình thường	< 200 mg/dL	52.385	0,7484
cholesterol	2	Cao hơn bình thường	200-239 mg/dL	9.549	0,1364
cholesterol	3	Rất cao	>= 240 mg/dL	8.066	0,1152
gluc	1	Bình thường	<= 99 mg/dL	59.479	0,8497
gluc	2	Cao hơn bình thường	100-125 mg/dL	5.190	0,0741
gluc	3	Rất cao	>= 126 mg/dL	5.331	0,0762

Kết quả kiểm tra schema, dtype và domain đều PASS. Dữ liệu đầu vào gốc không có missing value, nhưng có nhiều giá trị ngoại lai/phi lý về chiều cao, cân nặng và huyết áp. Các giá trị này không bị xóa trước split; thay vào đó được gắn invalid_flag và xử lý trong pipeline để tránh target-informed cleaning.




Hình 3.2: Diễn giải mức cholesterol và glucose trong dataset




Hình 3.3: Phân bố nhãn mục tiêu cardio


Trên tập train, phân bố nhãn gần cân bằng: cardio = 0 có 22.513 mẫu (0,5003) và cardio = 1 có 22.486 mẫu (0,4997). Do tỷ lệ lớp gần 50/50, mã nguồn không sử dụng SMOTE/oversampling; thay vào đó ưu tiên dùng class_weight trong một số mô hình và đánh giá bằng các chỉ số phù hợp cho bài toán y tế.



Hình 3.4: Phân bố các biến phân loại và nhị phân theo nhãn



Hình 3.5: KDE của một số biến lâm sàng quan trọng theo nhãn



Hình 3.6: Ma trận tương quan của các biến số lâm sàng

Các phân tích train-only cho thấy các biến huyết áp và tuổi là nhóm tín hiệu mạnh nhất. Spearman correlation với target cao nhất thuộc về ap_hi_clean (0,452), map_proxy

(0,434), pulse_pressure (0,358), ap_lo_clean (0,357), age_years (0,235), cholesterol (0,221), bmi (0,203) và gluc (0,093). Univariate ROC-AUC cũng xác nhận ap_hi_clean là biến đơn lẻ mạnh nhất với $AUC = 0,7517$.

3.2. Thiết kế chia tập dữ liệu chống rò rỉ

Để tránh cùng một cấu hình đặc trưng xuất hiện ở nhiều tập, mã nguồn tạo feature_signature từ toàn bộ đặc trưng đầu vào sau khi loại id và cardio. Kết quả audit ghi nhận 69.959 nhóm signature duy nhất, 24 dòng duplicate full-row không tính id và 17 nhóm feature trùng nhưng nhãn cardio mâu thuẫn với tổng 34 dòng. Các dòng này không bị xóa trước split, vì thao tác xóa dựa trên target có thể gây rò rỉ thông tin.

Bảng 3.4: Diễn giải mức cholesterol và glucose trong dataset

Tập	Số mẫu	Tỷ lệ lớp dương	Số nhóm	Mục đích
train	44.999	0,4997	44.973	Huấn luyện và cross-validation
val_cal	5.001	0,4999	4.997	Fit sigmoid calibrator
val_select	4.998	0,4998	4.997	Chọn model/calibrator/ensemble
val_threshold	5.002	0,4994	4.997	Khóa threshold quyết định
test	10.000	0,4997	9.995	Final reporting only

Tất cả pairwise group overlap giữa train, val_cal, val_select, val_threshold và test đều bằng 0. Như vậy, cùng một feature_signature không xuất hiện ở hai tập khác nhau, giúp hạn chế rò rỉ do duplicate hoặc record gần trùng.

3.3. Thiết kế pipeline tiền xử lý và feature engineering

Toàn bộ tiền xử lý được đóng gói trong sklearn Pipeline. Thành phần CardioFeatureEngineer chịu trách nhiệm nhận diện age tính theo ngày, quy đổi age_years, làm sạch chiều cao/cân nặng/huyết áp, tạo BMI, pulse pressure, MAP proxy, nhóm tuổi, nhóm BMI, giai đoạn huyết áp và các cờ invalid. ColumnTransformer sau đó xử lý từng nhóm đặc trưng bằng SimpleImputer, StandardScaler, OneHotEncoder hoặc passthrough.

Bảng 3.5: Các nhóm đặc trưng sau khi biến đổi lâm sàng

Nhóm	Đặc trưng tiêu biểu	Xử lý trong pipeline
Số liên tục	age_years, height_clean, weight_clean, bmi, ap_hi_clean, ap_lo_clean, pulse_pressure, map_proxy	SimpleImputer + StandardScaler
Ordinal	cholesterol, gluc	Giữ ordinal/passthrough; gán chú thích mức 1/2/3
Nhị phân	gender, smoke, alco, active	Passthrough sau kiểm tra domain
Flag	height_invalid_flag, weight_invalid_flag, bp_invalid_flag, bp_order_invalid_flag, bmi_invalid_flag	Giữ như tín hiệu phụ, không xóa dòng
Nhóm phân loại	age_group, bmi_group, bp_stage	Impute + OneHotEncoder


Audit train-only ghi nhận height ngoài [130, 220] cm có 65 dòng, weight ngoài [30, 180] kg có 7 dòng, blood pressure invalid có 840 dòng và ap_lo $\geq$ ap_hi có 774 dòng. Nhóm huyết áp bất thường có cardio rate 0,7488 so với 0,4950 ở nhóm còn lại; vì vậy invalid_flag được giữ lại như tín hiệu dự báo thay vì xóa bỏ tùy tiện.

3.4. So sánh 11 mô hình baseline

Mỗi mô hình được đóng gói cùng pipeline tiền xử lý và đánh giá bằng 5-fold StratifiedGroupKFold trên tập train. Các chỉ số chính gồm ROC-AUC, Average Precision/PR-AUC, Brier score, Accuracy, Precision, Recall, Specificity, F1 và F2.

Bảng 3.6: So sánh 11 mô hình baseline bằng cross-validation

Mô hình	ROC-AUC	PR-AUC	Brier	F1
DummyClassifier	0,4989	0,4992	0,5012	0,4978
LogisticRegression	0,7942	0,7743	0,1857	0,7108
GaussianNB	0,7667	0,7447	0,2596	0,6774
KNN	0,7873	0,7684	0,1874	0,7136
SVM	0,7935	0,7735	0,2053	0,7058
DecisionTree	0,7906	0,7632	0,1843	0,7169
RandomForest	0,7994	0,7800	0,1815	0,7258
ExtraTrees	0,7959	0,7771	0,1843	0,7222
XGBoost	0,8020	0,7838	0,1802	0,7256
LightGBM	0,8000	0,7815	0,1812	0,7255
CatBoost	0,8022	0,7841	0,1801	0,7261



Hình 3.7: So sánh 11 mô hình baseline trên các chỉ số chính

Kết quả cho thấy nhóm gradient boosting đạt hiệu năng cao nhất. CatBoost có ROC-AUC = 0,8022 và PR-AUC = 0,7841; XGBoost đạt ROC-AUC = 0,8020 và PR-AUC = 0,7838; LightGBM đạt ROC-AUC = 0,8000 và PR-AUC = 0,7815. Logistic Regression và SVM vẫn là baseline tuyến tính mạnh, còn DummyClassifier chỉ đóng vai trò mức sàn.

3.5. Tinh chỉnh siêu tham số, lựa chọn mô hình và kiểm định chéo lồng

Sau baseline, năm mô hình ứng viên gồm CatBoost, XGBoost, LightGBM, RandomForest và ExtraTrees được tinh chỉnh bằng RandomizedSearchCV với $n_iter = 25$. Scoring chính khi tuning là average_precision. Các mô hình boosting có thêm early

stopping khi phù hợp, sau đó được refit và chuyển sang bước chọn model/calibrator trên val_select. Kết quả mới cũng kiểm tra thêm các ensemble soft-voting từ các mô hình top, nhưng ensemble không vượt CatBoost + sigmoid theo selection score mặc định.

Bảng 3.7: Kết quả RandomizedSearchCV của top candidates

Mô hình	Best CV score	Thời gian (s)	Trạng thái early stopping
CatBoost	0,784497	581,8	refit_ok, best_iter = 396
XGBoost	0,784274	271,0	refit_ok, best_iter = 597
LightGBM	0,784199	523,9	refit_ok, best_iter = 252
RandomForest	0,780325	1.873,2	not_boosting
ExtraTrees	0,779721	1.115,8	not_boosting

Bảng 3.8: Kết quả chọn mô hình/calibrator trên val_select

Hạng	Mô hình	Calibrator	ROC-AUC	PR-AUC	Brier	ECE-10	Selection score
1	CatBoost	sigmoid	0,7941	0,7685	0,1841	0,0120	0,788908
2	CatBoost	none	0,7941	0,7685	0,1841	0,0130	0,788857
3	LightGBM	sigmoid	0,7937	0,7689	0,1843	0,0159	0,788603
4	LightGBM	none	0,7937	0,7689	0,1843	0,0171	0,788541
5	XGBoost	none	0,7936	0,7681	0,1845	0,0133	0,788392

Selection score mặc định được định nghĩa là $0,45 \cdot \text{ROC-AUC} + 0,35 \cdot \text{PR-AUC} + 0,20 \cdot (1 - \text{Brier}) - 0,05 \cdot \text{ECE-10}$. CatBoost + sigmoid đạt điểm cao nhất với selection score = 0,788908. EnsembleTop2_selection_weighted đạt 0,788898, gần như tương đương nhưng thấp hơn rất nhỏ, nên mô hình cuối vẫn là CatBoost + sigmoid theo quy tắc đăng ký trước. Kết luận đúng là CatBoost được chọn theo protocol đã khóa, không phải vì vượt trội tuyệt đối về mặt lâm sàng.

Bảng 3.9: Kết quả nested/outer CV của các mô hình top


Mô hình	Outer CV ROC-AUC	Outer CV PR-AUC	Brier mean
LightGBM	0,8022	0,7844	0,1801
XGBoost	0,8017	0,7838	0,1804
CatBoost	0,8014	0,7831	0,1804
RandomForest	0,7986	0,7804	0,1824
LogisticRegression	0,7943	0,7743	0,1858

3.6. Hiệu chuẩn xác suất và khóa ngưỡng quyết định

Trong bài toán y tế, xác suất dự đoán cần có ý nghĩa diễn giải. Vì vậy, sau khi mô hình được huấn luyện, mã nguồn fit sigmoid calibrator trên val_cal. Việc hiệu chuẩn được tách riêng khỏi train, val_select, val_threshold và test để tránh rò rỉ giữa các giai đoạn.

Bảng 3.10: So sánh CatBoost trước/sau sigmoid calibration

Chỉ số	Trước calibration	Sau calibration
Brier score	0,184093	0,184087
Log loss	0,549590	0,549596
ROC-AUC	0,794116	0,794116
Average Precision	0,768499	0,768499
ECE-10	0,013016	0,012027
Selection score	0,788857	0,788908




Hình 3.8: Calibration curve trước và sau hiệu chuẩn sigmoid

Ngưỡng quyết định mặc định 0,5 không phù hợp tối ưu cho mục tiêu sàng lọc vì bỏ sót bệnh nhân thường có chi phí cao hơn cảnh báo nhầm. Do đó threshold được khóa trên `val_threshold` theo F2-score với ràng buộc specificity $\geq 0,60$; trong đó F2 ưu tiên Recall hơn Precision.

Bảng 3.11: Khóa ngưỡng quyết định trên tập `val_threshold`

Threshold	Accuracy	Precision	Recall	Specificity	F2
0,300	0,6755	0,6253	0,8743	0,4772	0,8098
0,365	0,7089	0,6715	0,8167	0,6014	0,7828
0,400	0,7219	0,6963	0,7858	0,6581	0,7661
0,500	0,7365	0,7572	0,6954	0,7776	0,7069
0,600	0,7273	0,8062	0,5977	0,8566	0,6303



Hình 3.9: Đồ thị các chỉ số theo ngưỡng quyết định

Ngưỡng chính thức được khóa là $\text{threshold} = 0,3650$. Bootstrap trên val_threshold cho thấy ngưỡng F2-optimal tập trung quanh 0,3650, trung bình 0,36635, median 0,3650, khoảng 95% từ 0,3550 đến 0,3750 và độ lệch chuẩn 0,00538. Sau khi khóa ngưỡng này, mã nguồn mới mở tập hold-out test để báo cáo cuối cùng; không có bước chọn lại mô hình hoặc threshold theo test.

3.7. Đánh giá cuối cùng trên hold-out test

Tập test gồm 10.000 mẫu được giữ độc lập hoàn toàn từ đầu quy trình. Tập này không tham gia huấn luyện, tuning, calibration, model selection hoặc threshold tuning. Kết quả dưới đây vì vậy là đánh giá cuối cùng của pipeline đã khóa.


Bảng 3.12: Kết quả đánh giá mô hình trên hold-out test

Chỉ số	Giá trị
ROC-AUC	0,8083
Average Precision / PR-AUC	0,7995
Brier score	0,1774
Log loss	0,5331
ECE-10	0,0146
Accuracy tại threshold 0,3650	0,7161
Precision	0,6792
Recall / Sensitivity	0,8185
Specificity	0,6138
F1-score	0,7424
F2-score	0,7862


Bảng 3.13: Ma trận nhầm lẫn trên hold-out test

Thực tế / Dự đoán	Dự đoán 0	Dự đoán 1	Tổng
Thực tế 0	TN = 3.071	FP = 1.932	5.003
Thực tế 1	FN = 907	TP = 4.090	4.997
Tổng	3.978	6.022	10.000

Ma trận nhầm lẫn cho thấy mô hình phát hiện đúng 4.090/4.997 ca dương tính và bỏ sót 907 ca. Số false positive là 1.932, cao hơn false negative; đây là kết quả phù hợp với định hướng screening vì mô hình ưu tiên giảm bỏ sót bệnh nhân hơn là tối đa hóa accuracy.



Hình 3.10: Đường ROC và Precision-Recall trên hold-out test



Hình 3.11: Decision curve analysis trên hold-out test

Decision Curve Analysis cho thấy mô hình có Net Benefit dương và vượt các chiến lược cực đoan trong dải ngưỡng lâm sàng rộng; threshold 0,3650 nằm trong vùng có lợi ích. Kết quả này chỉ mang tính phân tích hỗ trợ quyết định, chưa phải bằng chứng triển khai lâm sàng.

3.8. Kiểm tra độ ổn định và độ tin cậy

Để tránh kết luận dựa trên một giá trị điểm duy nhất, mã nguồn thực hiện bootstrap 600 lần trên hold-out test, bootstrap độ ổn định ngưỡng trên `val_threshold`, learning curve, so sánh với Logistic Regression, cleaning sensitivity, multi-seed robustness và cost-sensitive threshold hậu nghiệm.


Bảng 3.14: Khoảng tin cậy 95% bằng bootstrap trên hold-out test

Chỉ số	Giá trị điểm	Cận dưới 95%	Cận trên 95%
ROC-AUC	0,8082	0,7997	0,8163
PR-AUC	0,7998	0,7870	0,8116
Recall	0,8185	0,8075	0,8285
Specificity	0,6138	0,5989	0,6278
Precision	0,6792	0,6681	0,6927
F2-score	0,7862	0,7767	0,7946
Accuracy	0,7160	0,7068	0,7249

Bảng 3.15: So sánh mô hình cuối với Logistic Regression trên test

Chỉ số	Logistic Regression	CatBoost + sigmoid	Chênh lệch
ROC-AUC	0,7976	0,8083	+0,0107
PR-AUC	0,7743	0,7995	+0,0252
Recall	0,7747	0,8185	+0,0438
F2-score	0,7600	0,7862	+0,0262
Brier score	0,1825	0,1774	-0,0051

Paired bootstrap AUC diff cho delta AUC = +0,0107 với $p < 0,001$; DeLong test có $z = 8,486$ và $p = 2,13e-17$; McNemar exact test có $p = 6,70e-05$. Các kiểm định này được dùng như phân tích hậu nghiệm, không dùng để chọn lại mô hình.



Hình 3.12: Learning curve của mô hình theo kích thước tập huấn luyện

Bảng 3.16: Robustness studies chính


Phân tích	Kết quả chính	Diễn giải
Cleaning sensitivity	ROC-AUC current = 0,8016; loose = 0,8015; strict = 0,8015	Không phụ thuộc mạnh vào một bộ ngưỡng làm sạch
Multi-seed	ROC-AUC mean = 0,801617; std = 0,000275	Ổn định qua seed 42, 2024, 2026
Cost-sensitive threshold	Threshold 0,150 tăng Recall lên 0,9886 nhưng Specificity còn 0,1267	Chỉ là phân tích hậu nghiệm, không thay threshold chính
Learning curve	Gap train-valid còn khoảng 0,010 ở kích thước lớn nhất	Không có dấu hiệu overfit nghiêm trọng
Độ ổn định ngưỡng	Bootstrap mean = 0,36635; median = 0,3650; 95% CI = [0,3550; 0,3750]; std = 0,00538	Ngưỡng 0,3650 ổn định, không phải điểm chọn ngẫu nhiên/knife-edge

3.9. Giải thích mô hình và tầm quan trọng đặc trưng


Mô hình được giải thích bằng permutation importance, stability importance, SHAP global/local và partial dependence. Các kết quả giải thích chỉ được diễn giải như bằng chứng tương quan dự báo, không phải quan hệ nhân quả.

Bảng 3.17: Tầm quan trọng đặc trưng top 10


Đặc trưng	SHAP mean(value)	Permutation importance
ap_hi_clean	0,5986	0,1213
cholesterol	0,2675	0,0286
age_years	0,2517	0,0255
map_proxy	0,1818	0,0053
bmi	0,0738	0,0005
weight_clean	0,0612	0,0004
active	0,0489	0,0036
age_group_60-69	0,0438	0,0005
gluc	0,0294	0,0010



Hình 3.13: SHAP summary plot cho các đặc trưng quan trọng nhất



Hình 3.14: SHAP dependence plot cho đặc trưng ap_hi_clean




Hình 3.15: SHAP dependence plot cho đặc trưng age_years

Kết quả nhất quán với kiến thức lâm sàng cơ bản: huyết áp tâm thu, cholesterol, tuổi, MAP proxy, BMI và cân nặng là các tín hiệu dự báo nổi bật. Mã nguồn mới sinh SHAP dependence cho 6 đặc trưng top, trong đó báo cáo minh họa các biến quan trọng nhất. Tuy nhiên, vì dữ liệu quan sát không có thiết kế can thiệp, không được kết luận rằng mô hình chứng minh quan hệ nhân quả.

3.10. Kiểm tra công bằng, drift và khả năng tổng quát hóa

Mã nguồn kiểm tra hiệu năng và calibration theo các nhóm giới tính, tuổi, BMI và giai đoạn huyết áp. Với gender, chênh lệch TPR khoảng 0,014 và selection rate khoảng 0,011. Với age_group, bmi_group và bp_stage, khoảng cách lớn hơn do nguy cơ nền và phân bố huyết áp khác nhau giữa các nhóm.



Hình 3.16: Calibration theo từng nhóm con (subgroup)

Bảng 3.18: Tổng hợp kiểm tra fairness theo nhóm

Nhóm	Max TPR diff	Max selection rate diff	Nhận xét
gender	0,0140	0,0111	Chênh lệch nhỏ, cần tiếp tục theo dõi
age_group	0,3275	0,7603	Khác biệt lớn do nguy cơ nền theo tuổi
bmi_group	0,3860	0,6199	Khác biệt liên quan phân bố BMI
bp_stage	0,6854	0,8610	Khác biệt lớn do huyết áp là tín hiệu mạnh

Drift monitoring giữa train và test bằng PSI/KS cho thấy PSI của các đặc trưng liên tục đều rất nhỏ; lớn nhất là BMI với PSI = 0,0025, thấp hơn nhiều so với ngưỡng cảnh báo 0,10. Điều này xác nhận train và test trong lần chia hiện tại cùng phân phối tương đối ổn định.

3.11. Thực nghiệm đối chiếu trên các dataset phụ

Để bổ sung phần so sánh với nguồn dữ liệu khác, đề tài xây dựng thêm ba notebook độc lập trên Heart Failure Prediction, Framingham Heart Study và Heart Disease Indicators 2020. Ba notebook này giữ cùng xương sống pipeline với bài chính: split trước

preprocessing, EDA trên tập huấn luyện, xử lý missing/encoded missing trong Pipeline, xử lý mất cân bằng bằng `class_weight` hoặc mô hình tương đương khi cần, tối ưu threshold trên validation và chỉ báo cáo kết quả cuối cùng trên test. Tuy nhiên, feature engineering được điều chỉnh theo schema từng dataset, vì không thể bê nguyên các đặc trưng BMI, pulse pressure hoặc MAP proxy từ Sulianova sang mọi nguồn dữ liệu.

Bảng 3.20: So sánh thực nghiệm giữa dataset chính và các dataset phụ


Dataset	Vai trò	Model tốt nhất	ROC - AUC	PR-AUC	Accuracy	Precision	Recall	F1/F2
Sulianova CVD	Chính	CatBoost + sigmoid	0,8083	0,7995	0,7161	0,6792	0,8185	F2 = 0,7862
Heart Failure Prediction	Phụ 1	Logistic Regression	0,9258	0,9272	0,8478	0,8033	0,9608	F1 = 0,8750
Framingham Heart Study	Phụ 2	Random Forest + sigmoid	0,6952	0,2970	0,6333	0,2400	0,6512	F1 = 0,3507
Heart Disease Indicators 2020	Phụ 3	Logistic Regression balanced	0,8406	0,3560	0,8701	0,3284	0,4954	F1 = 0,3950

3.12. Đóng gói mô hình và ứng dụng minh họa

Sau khi mô hình cuối được khóa, mã nguồn lưu model package bằng `joblib` để phục vụ tái sử dụng. Package gồm estimator CatBoost đã fit, sigmoid calibrator, threshold = 0,3650, feature contract, thông tin split/protocol, test metrics và các artifact báo cáo. Kết quả sanity check cuối xác nhận toàn bộ must-have artifacts đã được tạo đầy đủ.

Bảng 3.21: Thông số đóng gói mô hình và triển khai minh họa

Hạng mục	Giá trị / Mô tả
Mô hình đóng gói	CatBoost
Phương pháp hiệu chuẩn	Sigmoid / Platt scaling
Ngưỡng quyết định khóa	0,3650
Runtime	Python 3.12.12
Thư viện chính	scikit-learn 1.6.1, catboost 1.2.10, xgboost 3.2.0, lightgbm 4.6.0, shap 0.50.0
File mô hình	cardio_artifacts/models/final_model.joblib
Artifact báo cáo	model_card.json, model_card.md, report_artifact_binding.csv, patch_log.json
Chính sách test set	Final reporting only; không dùng để chọn model, calibrator hoặc threshold
Hướng triển khai	Streamlit hoặc REST API đọc package và feature contract



Hình 3.17: Giao diện ứng dụng dự đoán bệnh tim mạch

Ứng dụng minh họa cần nhận đúng schema đầu vào gồm tuổi, giới tính, chiều cao, cân nặng, huyết áp tâm thu/tâm trương, cholesterol ordinal, glucose ordinal, hút thuốc, uống rượu và vận động. Khi người dùng nhấn dự đoán, ứng dụng đóng gói dữ liệu thành

DataFrame một dòng, đưa qua pipeline và calibrator, sau đó so sánh xác suất calibrated với threshold 0,3650 để hiển thị nhãn nguy cơ.

Phần giao diện phải kèm cảnh báo rõ ràng: kết quả chỉ có ý nghĩa sàng lọc học thuật, không thay thế chẩn đoán y tế. Người có kết quả nguy cơ cao cần được khuyến nghị đi khám hoặc xét nghiệm xác nhận.

3.13. Kết chương

Chương 3 đã trình bày toàn bộ quy trình thực nghiệm chính trên Sulianova: kiểm tra dữ liệu, audit chống rò rỉ, split group-aware, EDA train-only, xây dựng pipeline, so sánh 11 mô hình, tuning top candidates, kiểm tra ensemble, chọn CatBoost + sigmoid trên val_select, khóa threshold 0,3650 trên val_threshold và đánh giá một lần trên hold-out test. Mô hình cuối đạt ROC-AUC = 0,8083, PR-AUC = 0,7995, Recall = 0,8185, Specificity = 0,6138 và F2-score = 0,7862 trên test.

Ngoài ra, chương này bổ sung thực nghiệm đối chiếu trên Heart Failure Prediction, Framingham Heart Study và Heart Disease Indicators 2020. Kết quả cho thấy cùng một khung pipeline có thể áp dụng cho nhiều dataset tim mạch, nhưng metric thay đổi đáng kể do khác schema, target, số mẫu và phân phối nhãn. Vì vậy, kết quả phụ không thay thế kết quả chính trên Sulianova và không được xem là external validation lâm sàng của mô hình cuối.

KẾT LUẬN

Đồ án “Nghiên cứu các thuật toán học máy và ứng dụng dự đoán bệnh tim mạch” đã hoàn thành quy trình nghiên cứu, thực nghiệm, đánh giá và đóng gói mô hình theo quy trình thực nghiệm mới. Nội dung kết luận dưới đây tổng hợp các kết quả chính, hạn chế và hướng phát triển theo đúng phạm vi bằng chứng của lần chạy hiện tại.

Kết quả đạt được

- Đã đọc và kiểm tra bộ Cardiovascular Disease Dataset gồm 70.000 bản ghi và 13 cột ban đầu; schema, dtype, domain đều hợp lệ và số missing đầu vào gốc bằng 0.
- Đã thiết kế quy trình chia dữ liệu chống rò rỉ thành train 44.999 mẫu, val_cal 5.001 mẫu, val_select 4.998 mẫu, val_threshold 5.002 mẫu và hold-out test 10.000 mẫu; tất cả pairwise group overlap bằng 0.
- Đã xây dựng CardioFeatureEngineer và ColumnTransformer trong Pipeline, tạo các đặc trưng age_years, BMI, pulse_pressure, map_proxy, bp_stage, age_group, bmi_group và invalid_flag theo quy tắc cố định.
- Đã huấn luyện và so sánh 11 mô hình bằng 5-fold StratifiedGroupKFold: DummyClassifier, LogisticRegression, GaussianNB, KNN, SVM, DecisionTree, RandomForest, ExtraTrees, XGBoost, LightGBM và CatBoost.
- Đã tinh chỉnh 5 mô hình ứng viên bằng RandomizedSearchCV với n_iter = 25; lựa chọn CatBoost + sigmoid trên val_select theo selection score đăng ký trước; kiểm tra thêm ensemble top models nhưng không thay đổi mô hình cuối vì EnsembleTop2_selection_weighted có score 0,788898, thấp hơn rất nhỏ so với CatBoost + sigmoid 0,788908.
- Đã khóa threshold = 0,3650 trên val_threshold, sau đó đánh giá độc lập trên hold-out test: ROC-AUC = 0,8083, PR-AUC = 0,7995, Brier = 0,1774, Accuracy = 0,7161, Precision = 0,6792, Recall = 0,8185, Specificity = 0,6138 và F2-score = 0,7862.

- Đã kiểm tra độ tin cậy bằng bootstrap 600 lần, bootstrap độ ổn định threshold, learning curve, cleaning sensitivity, multi-seed robustness, cost-sensitive threshold, drift monitoring, DeLong test, McNemar test và paired bootstrap so với Logistic Regression.

- Đã giải thích mô hình bằng permutation importance, stability importance, SHAP và partial dependence; các đặc trưng quan trọng nhất gồm ap_hi_clean, cholesterol, age_years, map_proxy, BMI, weight_clean, active, gluc và pulse_pressure.

- Đã lưu model package final_model.joblib cùng model_card.json/model_card.md, report_artifact_binding.csv và patch_log.json, hỗ trợ tái lập kết quả và triển khai ứng dụng minh họa.

Hạn chế

Mặc dù quy trình thực nghiệm đã được thiết kế chặt chẽ, đồ án vẫn tồn tại các hạn chế quan trọng cần nêu rõ khi bảo vệ:

- Dataset là dữ liệu công khai từ Kaggle/Sulianova, thiếu metadata chi tiết về bối cảnh thu thập, tiêu chuẩn gán nhãn, ethics statement và quần thể dân số.

- Các biến cholesterol và gluc chỉ là mức mã hóa ordinal 1/2/3; không có giá trị xét nghiệm thực tế của từng bệnh nhân, do đó không thể diễn giải như lipid panel hoặc glucose máu định lượng.

- Dữ liệu thiếu nhiều yếu tố nguy cơ quan trọng như LDL, HDL, triglyceride, HbA1c, ECG, troponin, tiền sử gia đình, thuốc đang dùng, bệnh nền và thông tin xã hội.

- Mô hình chính được đánh giá hold-out trong cùng nguồn dữ liệu. Các dataset phụ chỉ là thực nghiệm đối chiếu theo pipeline tương tự, không phải external validation lâm sàng của full model Sulianova.

- Các kết quả SHAP và permutation importance chỉ phản ánh tín hiệu dự báo thống kê, không chứng minh quan hệ nhân quả giữa đặc trưng và bệnh tim mạch.

- Ứng dụng minh họa chưa được kiểm thử đầy đủ về an toàn dữ liệu, bảo mật, drift monitoring định kỳ và quy trình human-in-the-loop trong môi trường y tế thật.

Hướng phát triển

- Thu thập hoặc hợp tác với cơ sở y tế để đánh giá trên cohort Việt Nam có cùng schema hoặc schema mở rộng, nhằm thực hiện external validation và prospective validation đúng nghĩa.
- Bổ sung các đặc trưng lâm sàng giàu thông tin hơn như lipid panel chi tiết, HbA1c, ECG, tiền sử gia đình, thuốc điều trị, bệnh nền và biomarker liên quan tim mạch.
- Nghiên cứu tái hiệu chuẩn xác suất, domain adaptation và drift monitoring định kỳ khi áp dụng cho quần thể hoặc cơ sở dữ liệu mới.
- Mở rộng khả năng giải thích mô hình bằng counterfactual explanations, anchor explanations, model card chuẩn hóa và giao diện giải thích dễ hiểu cho người dùng.
- Phát triển ứng dụng an toàn hơn bằng Streamlit hoặc REST API, có xác thực người dùng, mã hóa dữ liệu, logging, phân quyền, cảnh báo giới hạn sử dụng và cơ chế bác sĩ kiểm duyệt.
- Thử nghiệm quy trình triển khai tiền cứu trong môi trường giả lập hoặc bán thực tế để đánh giá tác động của mô hình tới quyết định sàng lọc.

Kết luận chung

Đồ án đã chứng minh tính khả thi của việc ứng dụng học máy vào bài toán dự đoán nguy cơ bệnh tim mạch từ các chỉ số khám sức khỏe cơ bản. Mô hình cuối CatBoost kết hợp sigmoid calibration đạt kết quả tốt trên hold-out test và được đánh giá bằng quy trình có kiểm soát rò rỉ dữ liệu, có hiệu chuẩn xác suất, có khóa ngưỡng độc lập, có bootstrap CI, có kiểm tra độ ổn định threshold, kiểm định thống kê và giải thích mô hình.

Tuy nhiên, kết quả hiện tại chỉ nên được xem là proof-of-concept học thuật phục vụ sàng lọc sơ bộ. Mô hình không được dùng để chẩn đoán hoặc ra quyết định y tế thật. Để có thể sử dụng trong thực tế, mô hình cần được xác thực ngoài trên dữ liệu lâm sàng phù hợp, tái hiệu chuẩn trên quần thể đích, kiểm thử an toàn và đặt trong quy trình chuyên môn có sự giám sát của nhân viên y tế.

TÀI LIỆU THAM KHẢO

- [1] World Health Organization (WHO), “Cardiovascular diseases (CVDs),” Fact Sheet, 2023. [Trực tuyến]. Có tại: [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))
- [2] T. Hastie, R. Tibshirani, và J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, 2nd ed. New York: Springer, 2009.
- [3] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd ed. Sebastopol, CA: O'Reilly Media, 2022.
- [4] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- [5] T. Chen và C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), 2016, pp. 785–794.
- [6] G. Ke et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017, pp. 3146–3154.
- [7] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, và A. Gulin, “CatBoost: Unbiased Boosting with Categorical Features,” in Advances in Neural Information Processing Systems (NeurIPS), vol. 31, 2018, pp. 6638–6648.
- [8] S. M. Lundberg và S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in Advances in Neural Information Processing Systems (NIPS), vol. 30, 2017, pp. 4765–4774.
- [9] E. R. DeLong, D. M. DeLong, và D. L. Clarke-Pearson, “Comparing the Areas Under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach,” Biometrics, vol. 44, no. 3, pp. 837–845, Sep. 1988.
- [10] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” Psychometrika, vol. 12, no. 2, pp. 153–157, Jun. 1947.

- [11] S. Ulianova, “Cardiovascular Disease Dataset,” Kaggle, 2019. [Trực tuyến]. Có tại: <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>
- [12] F. Soriano, “Heart Failure Prediction Dataset,” Kaggle, 2021. [Trực tuyến]. Có tại: <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>
- [13] Aasheesh, “Framingham Heart Study Dataset,” Kaggle. [Trực tuyến]. Có tại: <https://www.kaggle.com/datasets/aasheesh200/framingham-heart-study-dataset>
- [14] K. Pytlak, “Personal Key Indicators of Heart Disease,” Kaggle. [Trực tuyến]. Có tại: <https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease>